PROYECTO ACA 2 · APRENDIZAJE AUTOMÁTICO · PILAR SALUD

# NeumoScan AI

## Tamizaje de neumonía en radiografías de tórax pediátricas con una CNN

**Autora:** Claudia Teresa Aranguren Peña · **Docente:** Dr. Hamilton Rivera Flor · Especialización en Inteligencia Artificial · CUN

**Curso:** APRENDIZAJE AUTOMÁTICO/54ES2/SEGUNDO BLOQUE/26ES4 · Noviembre de 2026

## 1 Objetivo general

Desarrollar una **red neuronal convolucional** con *transfer learning* que estime la probabilidad de neumonía en radiografías de tórax pediátricas, y desplegarla en **Streamlit** como herramienta de tamizaje para priorizar la revisión médica.

## 2 Pregunta orientadora

¿Puede una CNN preentrenada detectar neumonía en radiografías de niños con **alta sensibilidad**, para que el menor número posible de enfermos pase sin ser priorizado, y explicar dónde mira para decidir?

## 3 Dataset y gestión SQL

**Chest X-Ray Images (Pneumonia)**: 5.856 radiografías de niños de 1 a 5 años; 73 % neumonía · 27 % normal. Inventario en **SQLite** y EDA con consultas SQL.

**Partición 4.059 / 878 / 919** · **0 pacientes repetidos**

## 4 Flujo metodológico

**① Exploración y SQL**
EDA en SQLite; división 70/15/15 **por paciente**, sin fuga.

**② Pipeline**
`tf.data` 224×224; aumento leve **sin volteo**; pesos por clase 1.82 / 0.69.

**③ Modelado**
MobileNetV2 congelada + cabeza densa; Adam 1e-3; *early stopping*.

**④ Evaluación**
Umbral fijado en validación (Recall ≥ 0.95); prueba usada **una sola vez**.

**⑤ Despliegue**
Streamlit Cloud: modelo, métricas reales y Grad-CAM en vivo.

## 5 Arquitectura de la red (CNN)

**Radiografía** 224 × 224 × 3 › **Aumento + escala** a [−1, 1] › **MobileNetV2** congelada 7×7×1280 › **Pooling global** + Dropout 30 % › **Sigmoide** P(neumonía)

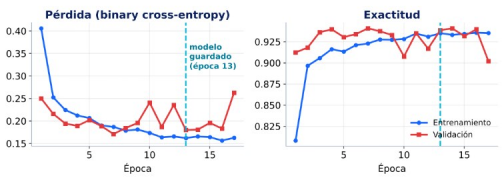
***Transfer learning*:** se entrenan solo **1.281** de 2,26 millones de parámetros. Pérdida: entropía cruzada binaria. Un *fine-tuning* (capas 100+, tasa 1e-5) se probó y **se descartó por sobreajuste**.

## 6 Métricas · prueba (919 imágenes, umbral 0.35)

| RECALL | ESPECIFICIDAD | PRECISIÓN | 218 VN | 13 FP |
|---|---|---|---|---|
| 0.961 | 0.944 | 0.981 | | |
| **F1-SCORE** | **ROC-AUC** | **ACCURACY** | **27 FN** | **661 VP** |
| 0.971 | 0.987 | 0.956 | | |

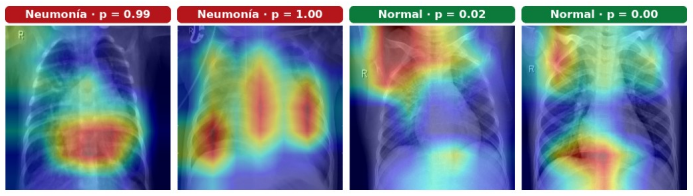
**Umbral 0.35 frente a 0.50:** los niños con neumonía no detectados bajan de **38 a 27**, a cambio de 3 falsas alarmas más (10 → 13). Detecta unos **96 de cada 100** enfermos.

## 7 Curvas de aprendizaje



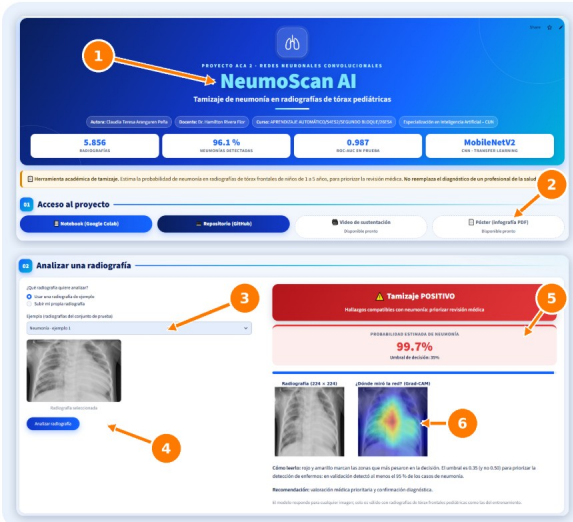

La pérdida de validación baja hasta la época 7 y luego oscila. El *early stopping* (AUC de validación) guardó la **época 13** y evitó el sobreajuste del final.

## 8 Explicabilidad: ¿dónde mira la red? (Grad-CAM)




En neumonía la red mira **los pulmones**. En algunos normales mira cuello o abdomen: posible **aprendizaje por atajos**, reportado como limitación.

## 9 Aplicación NeumoScan AI en Streamlit · [neumoscan-ai-ctap.streamlit.app](neumoscan-ai-ctap.streamlit.app)







1. **Portada**: el proyecto y sus cifras clave en un vistazo.
2. **Acceso**: notebook, GitHub, video y póster.
3. **Elegir radiografía**: un ejemplo de prueba o una propia.
4. **Analizar**: la CNN procesa la imagen en vivo.
5. **Resultado**: positivo o negativo y probabilidad frente al umbral del 35 %.
6. **Grad-CAM**: mapa de calor de dónde miró la red.
7. **Datos**: balance de clases y partición por paciente.
8. **Desempeño**: pestañas de pérdida, matriz, ROC, umbral y Grad-CAM.

## 10 Conclusiones

- La CNN detecta **96 de cada 100** niños con neumonía (AUC 0.987) entrenando solo la capa final, gracias al *transfer learning*.
- Dividir por paciente y fijar el umbral en validación dan métricas honestas, sin fuga de datos.
- Limitaciones: un solo centro, métricas por imagen y posible atajo en normales. Es **tamizaje**: no reemplaza el diagnóstico médico.

## 11 Reproducibilidad

Python 3.12 · TensorFlow 2.21
Semilla fija: 42
Partición guardada en SQLite
Modelo `.keras` con preprocesamiento
Código y datos de la app en GitHub

## 12 Acceso · clic en cada enlace

- **App en Streamlit ↗**
- **Notebook en Google Colab ↗**
- **Código en GitHub ↗**
- **Video de sustentación (YouTube) ↗**

## Referencias (APA 7)

Kermany, D. S., Goldbaum, M., Cai, W., Valentim, C. C. S., Liang, H., Baxter, S. L., McKeown, A., Yang, G., Wu, X., Yan, F., Dong, J., Prasadha, M. K., Pei, J., Ting, M. Y. L., Zhu, J., Li, C., Hewett, S., Dong, J., Ziyar, I., . . . Zhang, K. (2018). Identifying medical diagnoses and treatable diseases by image-based deep learning. *Cell, 172*(5), 1122–1131. https://doi.org/10.1016/j.cell.2018.02.010

Mooney, P. (2018). *Chest X-Ray Images (Pneumonia)* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L.-C. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 4510–4520). https://doi.org/10.1109/CVPR.2018.00474

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision* (pp. 618–626). https://doi.org/10.1109/ICCV.2017.74